

Temeraire: Redis-Reproduktion mit öffentlichem Code

Von der hugepage-aware Idee bis zum funktionierenden Experiment

Aldo Costa

Heinrich-Heine-Universität Düsseldorf

Juli 2026

Was wird hier reproduziert?

Temeraire

Hugepage-bewusster Backend-Allocator für
TCMalloc

Hunter et al., OSDI 2021

- Ziel im Paper: weniger TLB-Druck durch bessere Platzierung
- Ziel hier: der öffentliche Redis 6.0.9-Case-Study-Teil
- Kein Google-Fleet-Experiment, keine Produktions-Telemetrie

Arbeitsfrage

Kann die Redis-Methode mit öffentlichem Code und lokaler Hardware so nachgebaut werden, dass die kleine Effektgröße des Papers sichtbar wird?

Hugepages als Ausgangspunkt

- Normale Seiten: 4 KiB
- Hugepages: 2 MiB, also 512 normale Seiten
- Ein Hugepage-TLB-Eintrag deckt viel mehr Speicher ab
- Der Gewinn ist weniger Adressübersetzung, nicht ein größerer Cache


Problem

Hugepages helfen nur, wenn der Speicher passend ausgerichtet und zusammenhängend bleibt.

Allocator-Rolle

`malloc` entscheidet indirekt, ob live Objekte eine Hugepage erhalten, fragmentieren oder für die Freigabe blockieren.

Fragmentierung innerhalb einer Hugepage




- Freier Speicher reicht nicht aus, wenn er zwischen live Objekten liegt
- Teilfreigabe kann RAM sparen, aber Hugepage-Abdeckung zerstören
- Nichts freigeben kann TLB-Abdeckung halten, kostet aber Speicher

Temeraire macht diesen Trade-off explizit.

Es packt kleine Objekte bewusst auf schon teilgefüllte Hugepages.

Wo Temeraire in TCMalloc eingreift



- Obere Caches bleiben TCMalloc
- Temeraire ersetzt den Backend-Pageheap
- Reproduktion vergleicht deshalb Legacy Pageheap gegen den hugepage-aware Pfad

Vier Komponenten teilen die Anfragen nach Größe auf

HugeAllocator



holt ausgerichtete Hugepage-Bereiche vom System

HugeCache



hält leere, bereits backed Hugepages zur Wiederverwendung

HugeFiller



packt kleine Allokationen auf teilbelegte Hugepages

HugeRegion




behandelt mittlere Allokationen mit größerem Rest

Routing: $< 1 \text{ MiB} \rightarrow \text{HugeFiller}$; $1 \text{ MiB} - 1 \text{ GiB} \rightarrow \text{HugeCache} / \text{HugeRegion}$; $\geq 1 \text{ GiB}$

$\rightarrow \text{HugeCache}$. Redis trifft vor allem den kleinen Pfad.

HugeFiller verbindet Temeraire mit dem Redis-Workload

Weg einer kleinen Allokation



Wichtige Grenze

HugeFiller sieht keine Redis-Listen direkt. Er platziert die kleinen Spans hinter den schnellen TCMalloc-Caches.

Seine eigentliche Aufgabe

- freie Bereiche in bereits belegten Hugepages nutzen
- kleine Spans dichter zusammenhalten
- möglichst wenige Hugepages nur teilweise belegen

Warum das bei Redis helfen kann

Dichtere Belegung kann mehr aktiven Speicher mit Hugepage-TLB-Einträgen abdecken und leere Hugepages leichter freigeben.

Workload aus dem Paper

- Redis 6.0.9
- LPUSH von fünf Werten
- LRANGE 0 4
- 2000 Trials, je 1 Mio. Requests

Erwarteter Effekt

Redis erzeugt viele kleine Listen- und String-Allokationen. Wenn `HugeFiller` sie besser platziert, sinkt der TLB-Druck.

$$\text{kombiniert} = \frac{2}{1/r_{\text{LPUSH}} + 1/r_{\text{LRANGE}}}$$

Konsequenz für die Messung

Der erwartete Unterschied liegt unter einem Prozent. Reihenfolge, THP-Zustand und Laufzeit-Validierung dürfen nicht implizit bleiben.

Der Vergleich hat zwei getrennte Betriebsarten

Release-off

- keine periodische Pageheap-Freigabe
- freier Speicher bleibt länger beim Allocator
- je ein Legacy- und Temeraire-Run

Release-on

- Background-Thread gibt Speicher periodisch zurück
- dafür ist eine positive Rate nötig
- je ein Legacy- und Temeraire-Run

Zwei Dimensionen, nicht zwei Allocatoren


Der Backend-Vergleich bleibt immer **Legacy gegen Temeraire**. Er wird einmal ohne und einmal mit periodischer Freigabe gemessen. Das Paper nennt für Release-on keine konkrete Rate.

Zwei Libraries machen den Vergleich möglich

Rolle der Wrapper

Redis wird nicht zweimal umgebaut. Stattdessen werden zwei kleine TCMalloc-Shared-Libraries gebaut und beim Start in den Prozess geladen.

- gleicher Redis-Build
- gleiche Wrapper-Quelle
- unterschiedliche TCMalloc-Backend-Konfiguration



Abgrenzung

Der Wrapper ist kein neuer Allocator. Er macht den historischen TCMalloc-Code preloadbar, damit der Legacy-vs.-Temeraire-Pfad messbar wird.


Bazel baut die zwei TCMalloc-Varianten

Rolle von Bazel


Bazel ist das Build-System von TCMalloc. Es kennt dessen Quellcode, Abhängigkeiten und Link-Regeln.

- TCMalloc ist selbst ein Bazel-Projekt
- Abseil und interne Targets kommen aus dem nativen Build-Graph
- `want_no_hpaa` ist ein TCMalloc-Target, kein Runtime-Flag

Bazel brachte TCMallocs Build-Graphen mit: Abseil, interne Targets und Link-Semantik mussten nicht in CMake nachgebaut werden.



So sollte ein gültiges Messpaar ablaufen



 Umgebung	 Pro Run	 Pro Messpaar
• Docker: Debian 12 (bookworm) • WSL2-Kernel 6.6.114.1, x86_64 • Host-CPU: Intel i7-10700K	• 2000 Trials; je 1 Mio. Requests • genau eine Library und ein Release-Regime • Library, Rate und THP bestätigen	• gleiche Parameter und Release-Einstellung • Legacy und Temeraire getrennt • danach Delta berechnen

Erster Hiccup: Der Build war nicht übertragbar

Was nicht sauber funktionierte

- Moderner TCMalloc-Stand passte nicht zum historischen Wrapper
- Externer Wrapper erhielt nicht alle internen Abhängigkeiten
- Legacy-Target war außerhalb des Build-Graphen nicht sichtbar

Was am Ende funktionierte


- Wrapper im historischen TCMalloc-Quellbaum
- passende Bazel-Version festlegen
- denselben Compiler für alle Build-Schritte verwenden

Ein erfolgreicher Start beweist noch nicht den Allocator

- Redis kann weiter `mem_allocator: libc` melden
- Diese Meldung kommt aus der Redis-Build-Konfiguration
- Für `LD_PRELOAD` zählt, was der Prozess wirklich mappt

Prüfung

`/proc/$pid/maps` muss die passende Library zeigen:
`libtcmalloc_legacy.so` oder
`libtcmalloc_temeraire.so`.



Ohne aktive Hugepages misst der Lauf nicht Temeraire

Beobachtung in frühen Runs

```
AnonHugePages: 0kB
```

Redis lief, die Allocator-Varianten liefen, aber der Hugepage-Mechanismus war nicht belegt.

Fix im Harness

- `thp-before.txt` und `thp-after.txt`
- `memory-sample-0250..2000.txt`
- `smaps_rollup` mit `AnonHugePages`
- nur THP-aktive Runs für das Paper-Signal verwenden

Kriterium für gültige Runs

Spätere Runs liefen mit `[always] madvise never`; Redis-Snapshots zeigten 14–18 MiB `AnonHugePages` im Prozess. Erst dann war der Hugepage-Pfad wirklich Teil der Messung.

Release-on war faktisch nicht eingeschaltet

▶ Was lief

- Background-Thread gestartet
- Per-CPU-Caches wurden gepflegt

⚠ Was fehlte

Release-Rate nicht gesetzt: TCMalloc blieb bei 0 B/s. Damit gab es keine periodische Pageheap-Freigabe.

Konsequenz

Die alten Werte waren kein Release-on-Ergebnis. Der korrigierte Lauf setzt eine positive Rate explizit; das Paper nennt seine Rate nicht.

Release-off liegt nahe am kleinen Paper-Effekt

Paar	Reihenfolge	Delta
Paar 1	L first	+1.88%
Paar 2	L first	+0.43%
Paar 3	T first	+0.48%
Paar 4	L first	-0.76%
Paar 5	T first	+3.46%

Befund

Vier von fünf THP-aktiven vollständigen Runs favorisieren Temeraire. Der Median liegt bei +0.48%.

Paper-Vergleich

Redis[†] im Paper: +0.75%
Periodische Freigabe deaktiviert.

Tabelle lesen: Jede Zeile ist ein Legacy/Temeraire-Paar. Ein positives Delta bedeutet: Temeraire war schneller.

Release-on zeigt keinen stabilen Paper-Effekt

Rate	Paar 1	Paar 2	Paar 3	Paar 4	Median
16 MiB/s	+1.91%	-0.16%	-0.27%	-1.37%	-0.21%
64 MiB/s	-6.88%	+2.10%	+11.49%	+12.21%	+6.80%
256 MiB/s	+15.73%	-0.09%	+0.50%	-0.77%	+0.20%

Tabelle lesen: Jede Zelle ist das Delta eines Legacy/Temeraire-Paars. Positiv bedeutet: Temeraire war schneller.

Lokaler Befund

Mediane: -0.21%, +6.80%, +0.20%. Die drei Raten ergeben keinen monotonen oder stabilen Trend.

Paper-Vergleich

Redis[†] im Paper: +0.44%. Die lokale Matrix reproduziert diesen kleinen Effekt nicht stabil.

Host-Drift ist größer als der erwartete Effekt

Auswertbarer Befund

Release-off liegt mit +0.48% Median im kleinen Effektbereich des Paper-Werts von +0.75%. Die fünf Run-Paare streuen jedoch deutlich.

Korrigierter Befund

Release-on ist technisch korrekt gemessen, zeigt aber keinen stabilen Rate-Trend. Host-Drift ist größer als der Paper-Effekt.

Vertretbare Aussage

Das Artefakt rekonstruiert den Redis-Vergleich mit öffentlichem Code. Der korrigierte Lauf zeigt vor allem die Grenze konsekutiver Ein-Stunden-Runs.

Was diese Reproduktion nicht zeigen kann

Nicht reproduziert

- Google-Fleet-Experiment
- Produktions-Rollout
- interne Allocator-Binaries
- exakte Paper-Hardware

Lokale Abweichungen

- Docker/WSL2 und geteilter Kernel
- Consumer i7 statt Skylake Xeon Server
- THP-Policy aus der Host/VM-Umgebung
- Public TCMalloc als historische Annäherung

Nutzen der Grenzen

Sie trennen den methodisch reproduzierten Redis-Pfad von den Teilen des Papers, die ohne Google-Infrastruktur nicht nachstellbar sind.

Technische Lektion

Der schwere Teil war nicht `redis-benchmark`, sondern der Weg zu einem echten Legacy-vs.-Temeraire-Vergleich mit aktiven Hugepages.

- Vergleich aus public TCMalloc rekonstruiert
- Preload zur Laufzeit validiert
- THP-Fehlerbild gefunden und instrumentiert
- Release-on korrigiert und mit drei Raten neu gemessen

Endstand

Release-off zeigt ein kleines positives Mediansignal bei hoher Streuung. Release-on ist aktiv, aber Host-Drift verhindert ein stabiles Ergebnis.