

Temeraire: Redis-Reproduktion mit öffentlichem Code

Von der hugepage-aware Idee bis zum funktionierenden Experiment

Aldo Costa

Heinrich-Heine-Universität Düsseldorf

Juli 2026

Was wird hier reproduziert?

Temeraire

Hugepage-bewusster Backend-Allocator für
TCMalloc

Hunter et al., OSDI 2021

- Ziel im Paper: weniger TLB-Druck durch bessere Platzierung
- Ziel hier: der öffentliche Redis 6.0.9-Case-Study-Teil
- Kein Google-Fleet-Experiment, keine Produktions-Telemetrie

Arbeitsfrage

Kann die Redis-Methode mit öffentlichem Code und lokaler Hardware so nachgebaut werden, dass die kleine Effektgröße des Papers sichtbar wird?

Hugepages als Ausgangspunkt

- Normale Seiten: 4 KiB
- Hugepages: 2 MiB, also 512 normale Seiten
- Ein Hugepage-TLB-Eintrag deckt viel mehr Speicher ab
- Der Gewinn ist weniger Adressübersetzung, nicht ein größerer Cache


Problem

Hugepages helfen nur, wenn der Speicher passend ausgerichtet und zusammenhängend bleibt.

Allocator-Rolle

`malloc` entscheidet indirekt, ob live Objekte eine Hugepage erhalten, fragmentieren oder für die Freigabe blockieren.

Fragmentierung innerhalb einer Hugepage




- Freier Speicher reicht nicht aus, wenn er zwischen live Objekten liegt
- Teilfreigabe kann RAM sparen, aber Hugepage-Abdeckung zerstören
- Nichts freigeben kann TLB-Abdeckung halten, kostet aber Speicher

Temeraire macht diesen Trade-off explizit.


Es packt kleine Objekte bewusst auf schon teilgefüllte Hugepages.

Wo Temeraire in TCMalloc eingreift



- Obere Caches bleiben TCMalloc
- Temeraire ersetzt den Backend-Pageheap
- Reproduktion vergleicht deshalb Legacy Pageheap gegen den hugepage-aware Pfad

Temeraire Backend



Redis relevant: Der Listen-Workload trifft vor allem den kleinen Pfad über **HugeFiller**.

Workload aus dem Paper

- Redis 6.0.9
- LPUSH von fünf Werten
- LRANGE 0 4
- 2000 Trials, je 1 Mio. Requests

Erwarteter Effekt

Redis erzeugt viele kleine Listen- und String-Allokationen. Wenn `HugeFiller` sie besser platziert, sinkt der TLB-Druck.

$$\text{kombiniert} = \frac{2}{1/r_{\text{LPUSH}} + 1/r_{\text{LRANGE}}}$$


Konsequenz für die Messung

Der erwartete Unterschied liegt unter einem Prozent. Reihenfolge, THP-Zustand und Laufzeit-Validierung dürfen nicht implizit bleiben.

Rolle der Wrapper

Redis wird nicht zweimal umgebaut. Stattdessen werden zwei kleine TCMalloc-Shared-Libraries gebaut und beim Start in den Prozess geladen.

- gleicher Redis-Build
- gleiche Wrapper-Quelle
- unterschiedliche TCMalloc-Backend-Konfiguration



Abgrenzung


Der Wrapper ist kein neuer Allocator. Er macht den historischen TCMalloc-Code preloadbar, damit der Legacy-vs.-Temeraire-Pfad messbar wird.

Problem

Der Vergleich sollte nicht an selbst nachgebauten Link-Flags oder unvollständigen TCMalloc-Abhängigkeiten hängen.

- TCMalloc ist selbst ein Bazel-Projekt
- Abseil und interne Targets kommen aus dem nativen Build-Graph
- `want_no_hpaa` ist ein TCMalloc-Target, kein Runtime-Flag

Bazel brachte TCMallocs Build-Graphen mit: Abseil, interne Targets und Link-Semantik mussten nicht in CMake nachgebaut werden.



Codepfad: Wrapper und Bazel

Bazel-Target für Legacy

```
cc_binary(  
  name = "temeraire_libtcmalloc_legacy.so",  
  srcs = ["temeraire_wrapper.cc"],  
  linkshared = 1,  
  malloc = "//tcmalloc",  
  deps = ["//tcmalloc:want_no_hpa"],  
)
```

Temeraire-Target

```
name = "temeraire_libtcmalloc_temeraire.so"  
malloc = "//tcmalloc"
```

Auswahl beim Redis-Start

```
LD_PRELOAD="$GOOGLE_TCMALLOC_LEGACY_LIB"  
LD_PRELOAD="$GOOGLE_TCMALLOC_TEMERAIRE_LIB"
```

Startpunkt: falsche Nähe zum Paper

Vorher

- Redis 7.2.5 statt Redis 6.0.9
- glibc gegen gperftools
- kein Legacy-Pageheap gegen Temeraire
- Scope war anfangs zu breit formuliert


Entscheidung

Das Artefakt wird auf den Redis-Case-Study-Teil eingegrenzt. Die Fleet- und Rollout-Ergebnisse bleiben außerhalb der Reproduktion.

Erster Fix

Erst die Behauptung begrenzen, dann die Technik bauen.

Umbau 1: Den richtigen Vergleich bauen



- Der historische Commit enthält noch den Schalter für den Legacy-Pfad
- Beide Varianten kommen aus derselben Wrapper-Quelle
- Die intendierte Differenz ist der TCMalloc-Backend-Pfad

Was nicht sauber funktionierte

- Moderner TCMalloc-Checkout passte nicht zur Wrapper-Strategie
- Externer Bazel-Wrapper erbte nicht alle Dependencies
- `want_no_hpaa` war nicht global sichtbar


Was am Ende funktionierte

- Wrapper in `tcmalloc/testing`
- Bazelisk und Bazel-Version pinnen
- LLVM-Pfad durch Make, Autotools und Bazel reichen
- fehlende Release-Symbole dynamisch auflösen

- Redis kann weiter `mem_allocator: libc` melden
- Diese Meldung kommt aus der Redis-Build-Konfiguration
- Für `LD_PRELOAD` zählt, was der Prozess wirklich mappt

Prüfung

`/proc/$pid/maps` muss die passende Library zeigen:
`libtcmalloc_legacy.so` oder
`libtcmalloc_temeraire.so`.



Fehlerbild: THP war nicht aktiv genug

Beobachtung in frühen Runs

`AnonHugePages: 0 kB`

Redis lief, die Allocator-Varianten liefen, aber der Hugepage-Mechanismus war nicht belegt.


Fix im Harness

- `thp-before.txt` und `thp-after.txt`
- `memory-sample-0250..2000.txt`
- `smaps_rollup` mit `AnonHugePages`
- nur THP-aktive Runs für das Paper-Signal verwenden

Kriterium für gültige Runs

Spätere Runs liefen mit `[always] madvise never`; Redis-Snapshots zeigten 14–18 MiB `AnonHugePages` im Prozess. Erst dann war der Hugepage-Pfad wirklich Teil der Messung.

Ablauf des gültigen Runs



Was technisch passiert

- ein Redis-Binary, zwei TCMalloc-.sos
- Legacy: want_no_hpa; T: HPAA aktiv
- LD_PRELOAD wählt pro Redis-Prozess

Was als Ergebnis bleibt

- summary.csv: LPUSH/LRANGE-Mittel
- Snapshots: THP und AnonHugePages
- Delta nur gegen passenden Legacy-Run

Konfiguration

- 2000 Trials pro Modus
- 1 Mio. Requests pro Trial
- 50 Clients, Pipeline 16
- Redis 6.0.9, TCMalloc 8e534f...

Auswertung

- `summary.csv`: Mittelwert für LPUSH und LRANGE
- `trials.csv`: alle Einzelmessungen bleiben erhalten
- harmonisches Mittel als kombinierte Rate
- Temeraire-Delta immer gegen passenden Legacy-Run

Lesart

Bei Effekten unter einem Prozent ist ein einzelner lokaler Run kein Urteil. Die Wiederholungen zeigen eher ein Muster als eine exakte Zahl.

Run	Reihenfolge	Delta
THP fixed-order	L first	+1.88%
balanced 1	L first	+0.43%
balanced 2	T first	+0.48%
balanced 3	L first	-0.76%
balanced 4	T first	+3.46%

Befund

Vier von fünf THP-aktiven vollständigen Runs favorisieren Temeraire. Der Median liegt bei +0.48%.

Paper-Vergleich

Redis[†] im Paper: +0.75%
Periodic release disabled.

Run	Reihenfolge	Delta
THP fixed-order	L first	+0.26%
balanced 1	L first	+0.12%
balanced 2	T first	+0.38%
balanced 3	L first	-2.34%
balanced 4	T first	-12.02%
targeted rerun	T first	+0.12%

Ausreißer

Balanced 4 zeigte -12.02%, aber ohne Redis-Fehler und ohne offensichtlichen RSS- oder AnonHugePages-Kollaps.

Diagnose-Rerun

Der gezielte Release-on-Rerun mit Temeraire zuerst kam auf +0.12%. Deshalb wird -12.02% nicht als stabiler Allocator-Effekt gelesen.

Rerun-Rohwerte: T LPUSH=786686, LRANGE=1195121; L LPUSH=787017, LRANGE=1190716.

Stärkere Aussage

Release-off reproduziert die Richtung und die Größenordnung des Redis-Signals: lokal +0.48% Median, Paper +0.75%.

Schwächere Aussage

Release-on bleibt nahe null bis klein positiv, mit einem großen lokalen Ausreißer. Die exakte Table-1-Zahl wird nicht robust reproduziert.

Vertretbare Aussage

Das Artefakt reproduziert die Redis-Methode und landet oft im kleinen Effektbereich des Papers, sobald THP wirklich aktiv ist.

Nicht reproduziert

- Google-Fleet-Experiment
- Produktions-Rollout
- interne Allocator-Binaries
- exakte Paper-Hardware

Lokale Abweichungen

- Docker/WSL2 und geteilter Kernel
- Consumer i7 statt Skylake Xeon Server
- THP-Policy aus der Host/VM-Umgebung
- Public TCMalloc als historische Annäherung

Nutzen der Grenzen

Sie trennen den methodisch reproduzierten Redis-Pfad von den Teilen des Papers, die ohne Google-Infrastruktur nicht nachstellbar sind.

Technische Lektion

Der schwere Teil war nicht `redis-benchmark`, sondern der Weg zu einem echten Legacy-vs.-Temeraire-Vergleich mit aktiven Hugepages.

- Vergleich aus public TCMalloc rekonstruiert
- Preload zur Laufzeit validiert
- THP-Fehlerbild gefunden und instrumentiert
- Balanced Runs und gezielter Rerun zur Einordnung genutzt

Endstand

Release-off zeigt ein wiederkehrendes kleines positives Signal. Release-on ist verrauscht. Das Ergebnis ist eine vorsichtige Redis-Reproduktion, keine Fleet-Reproduktion.